AI notes: Discussion on Model Quantization, Conversion and Data Provision on Apr 16, 2026

> Title: Discussion on Model Quantization, Conversion and Data Provision
>
> Time: Apr 16, 2026 (Thu) 09:41 - 10:23 (GMT+08)
>
> Participants: Bowen QING Jialin MA Wanzhe ZHANG

> AI-generated notes might be inaccurate. Please use with caution.

AI notes benefits introduction [Export is restricted for this type of content.]

Summary

Bowen QING 10S10395 2026-04-19 10:06 UTC

BERT模型量化精度问题分析与解决

核心结论：
- BERT模型量化精度下降主因是分类头未一同量化，需采用W8A16方案
- 章万哲将基于卿博文提供的材料完成转换并指导后续流程
- 需使用量化平滑工具（seqmse/adaround）并注意AI met库版本

问题诊断与方案

量化精度下降问题

分类头需与编码器一同量化

- **量化后模型精度** 大幅下降
- 分类头 **未与编码器一同量化**
- 输出结果需确认是否经过 **反量化**
- 校准数据集大小与批次影响不大

量化平滑与工具

- 直接量化 **未做平滑** 导致问题
- 需使用 **seqmse或adaround工具**
- 工具位于 **AI met库** 中
- 需注意AI met库的 **版本匹配**

后续任务与分工

后续任务分工

章万哲负责模型转换与教学

- 卿博文提供 **模型、数据与脚本**
- 章万哲负责完成 **模型转换**
- 章万哲需 **指导卿博文** 转换过程
- 采用 **W8A16量化** 而非W4

模型转换方案

- 分类头与编码器可 **一同或分开转换**
- 最终需在 **NPU上运行** 所有部分
- 混合量化方案 **复杂且不必要**
- 优先确保转换流程 **正常输出**

内容由 AI 生成

本次会议主要围绕模型量化、模型转换以及数据提供等问题展开讨论，确定了量化处理方法、模型转换任务分配和数据提供内容，内容如下：

- **模型量化问题**
  - **量化平滑处理**
    - 问题指出：章万哲指出直接复制 vision 进行量化，未做量化平滑，仅计算激活值校准，导致量化结果有问题。
    - 解决建议：建议使用 seqmse 或 adaround 方法进行量化平滑，工具在 AI met 中。
- **AI met 库版本问题**
  - 版本差异：卿博文发现自己安装的 AI met 库不完整，且版本与章万哲不同，自己安装的是 AI met touch 2.28，章万哲使用的是 Docker 自带版本，且比卿博文的版本老。
  - 处理建议：章万哲提醒要装对版本，但认为版本差异影响不大。

用户	AI met组件	版本	安装来源
章万哲	• AI MET • AI MET common • AI MET touch	较老版本	Docker自带
卿博文	AI MET touch	2.28	手动pip安装

版本差异可能导致环境配置问题，建议统一使用Docker自带版本以避免兼容性风险。

AI 生成

AI met库环境对比

- **量化模型精度问题**
  - 精度下降情况：卿博文在 step two 跑完后，将量化模型的 last hidden state 接到 Pytorch 的分类头，精度掉得很厉害，20 分类准确度为 30%。
  - 原因分析：章万哲认为可能是未做平滑以及输出结果未反量化导致，建议先做平滑再观察情况。
  - 反量化探讨：章万哲解释量化原理中包含 scale 参数，若未做反量化，数值范围可能不正常。卿博文询问未做反量化对 example1 导出和 base ONNX 的影响，章万哲表示不确定。
- **test Vector 问题**
  - 数据使用情况：卿博文在 step one 中使用真实数据作为 calibration source，test Vector 原本代码使用 dummy input，但卿博文不确定自己使用的情况。
  - 结果差异：使用 test Vector 测试掉点大，未使用 test Vector 测试掉点小，章万哲认为若使用 test Vector，结果应与 step one 相同，怀疑测试方法有问题。

- **模型转换建议**
  - **分类头处理**
    - 问题提出：卿博文在模型转换时未将 head 放到模型里。
    - 解决建议：Jialin MA 建议将 head 放到模型里一起转换，也可尝试混合量化，但认为 bert 采用 W8A16 精度即可。
  - **KV 缓存管理**
    - 问题描述：章万哲提出用 qnn-net-run 跑 QWEN 3 view 且切片时，KV 缓存需手动管理，测试代码复杂。
    - 解决方案：Jialin MA 表示后续会使用自己的推理框架，避免 KV cache 管理问题。同时提到在 ONNX 上固定 context lens 时，需动态刷新 attention mask 和 position embedding。
- **后续工作安排**
  - **资料提供**：卿博文将数据集、模型权重、推理脚本和训练脚本等资料打包发给章万哲，其中模型权重为未量化的 Pytorch 权重。
  - **模型转换与教学**：章万哲使用卿博文提供的数据和权重进行模型转换，并教会卿博文转换方法。
  - **持续探索**：卿博文表示会尝试进行平滑量化，双方有新发现随时同步。

AI notes feedback collection [Export is restricted for this type of content.]

Action items

- [ ] 模型权重转换：将卿博文提供的运行脚本、权重和测试工具进行转换，采用 W8A16 格式，确保模型正常输出，并教导卿博文转换方法（来自Jialin MA） Wanzhe ZHANG
- [ ] 平滑量化尝试：尝试使用平滑量化的方法对模型进行优化，与章万哲保持新发现的同步 Bowen QING

AI notes feedback collection [Export is restricted for this type of content.]

Notable quotes

Workflow Recipes [Export is restricted for this type of content.]

Links

- Meeting transcript
  - Discussion on Model Quantization, Conversion and Data Provision 2026-04-16

Bowen QING 10S10395 2026-04-19 10:06 UTC