NLU 自动标注样本分布统计

1. 数据集概览 (N=938)

训练集与验证集采用约 **9:1** 的比例进行切分。

数据集阶段	样本数量 (N)	意图类数	槽位键数
训练集 (Train)	845	22	22
验证集 (Test)	93	19	11
全量数据 (Total)	938	22	22

---

2. 意图分布对照表 (Intent Distribution)

该表反映了模型需要识别的操作类型及其在训练/验证集中的覆盖情况。

意图名称 (Intent)	训练集	验证集	全量合计	占比 (%)
qa_knowledge (知识问答)	131	9	140	14.93%
ac_adjust (空调调节)	111	12	123	13.11%
seat_adjust (座椅调节)	84	8	92	9.81%
win_adjust (车窗调节)	73	9	82	8.74%
media_music_control (音乐控制)	54	3	57	6.08%
refuse_policy (拒绝策略)	46	5	51	5.44%
vol_adjust (音量调节)	37	8	45	4.80%
consultant (顾问咨询)	34	8	42	4.48%
media_video_control (视频控制)	37	3	40	4.26%
amb_adjust (氛围灯调节)	33	3	36	3.84%

shade_adjust (遮阳帘调节)	30	6	36	3.84%
qa_chitchat (闲聊)	27	6	33	3.52%
nav_traffic_query (交通查询)	25	2	27	2.88%
nav_route_navigate (路线导航)	21	1	22	2.35%
expert_podcast (播客)	21	1	22	2.35%
paint_control (车载绘画/涂装)	19	3	22	2.35%
nav_search_poi (地点搜索)	16	2	18	1.92%
tour_plan (行程规划)	15	0	15	1.60%
ui_general_command (通用UI指令)	8	3	11	1.17%
app_switch (应用切换)	10	0	10	1.07%
travel_record_control (行程记录)	8	1	9	0.96%
greet_reminder (问候提醒)	5	0	5	0.53%

---

3. 槽位键分布表 (Slot Key Distribution)

展示了模型需要从句子中提取的关键信息项（特征）。

槽位键 (Slot Key)	训练集	验证集	全量合计
predicate (动作谓词)	608	65	673
object (操作对象)	478	44	522
degree (幅度/程度)	226	37	263
position (方位)	53	7	60
ac_work_mode (空调模式)	28	4	32
function (功能)	20	2	22
source_channel (音源渠道)	17	3	20
open_mode (打开模式)	14	2	16
artist (艺术家)	15	0	15
color_or_brightness (颜色亮度)	10	1	11
air_circulation (空气循环)	9	1	10
refuse_reason (拒绝原因)	10	0	10
temp_value (温度值)	9	0	9
fan_level (风量等级)	8	0	8
scene_type (场景类型)	3	1	4
album (专辑)	4	0	4
style (风格)	3	0	3
party_size (人数)	3	0	3
time_point (时间点)	3	0	3
route_pref (路径偏好)	2	0	2
episode (剧集/集数)	2	0	2
origin (出发地)	1	0	1

4. 样本复杂度统计 (Slots per Sample)

展示了每个样本中包含槽位个数的分布情况，体现了语义解析的难度。

槽位个数	训练集条数	验证集条数	全量合计
0 个槽	121	19	140
1 个槽	174	14	188
2 个槽	345	36	381
3 个槽	167	17	184
4 个槽	31	5	36
5 个槽	5	2	7
6 个槽	2	0	2

💡 数据观察简评：

1. **数据倾斜**：`qa_knowledge` 和 `ac_adjust` 是主要意图，合占约 28%。
2. **验证集覆盖度**：验证集漏掉了 3 个意图（`tour_plan`，`app_switch`，`greet_reminder`）以及 11 个槽位键，这可能导致在评估这些特定类别时缺乏准确性。
3. **任务难度**：绝大多数样本集中在 1-3 个槽位，语义解析压力适中。